

Fact vs Fiction: LLM 신뢰도 비교 실험

 GPT ·  Claude ·  Gemini 사실 기반 정답률·오류·Hallucination 분석

"32개 질문 데이터셋 기반 LLM 실험 설계 및 분석"

팀명: FactCheck AI

팀원: 임보영(2023082933) · 최은연(2023034975) · 최희조(2023079207)

목차

01

프로젝트 개요

- LLM 신뢰도 비교 필요성
- 프로젝트 목적 및 연구 질문

03

평가 기준

- Skill Tag & 난이도 분류
- 난이도·Skill Tag 정의
- Hallucination 분류 기준
- 채점 방식(1/0.5/0)

05

종합 비교

- 모델별 강점·약점 프로파일
- 난이도별 성능 특징
- 활용 목적별 모델 선택 가이드

02

데이터셋 구축 & 실험 설계

- 질문 데이터셋 구성(텍스트 28 · 이미지 4)
- 정답·응답 데이터 구축
- 실험 파이프라인

04

모델별 성능 분석

- 정확도(Accuracy) 비교
- 안정성(Variance) 분석: 전체·난이도별
- Hallucination 패턴 분석
- Skill Tag별 성능 차이

06

결론 & 시사점


- 핵심 인사이트
- LLM 신뢰도 평가의 중요성

PART

01

프로젝트 개요

AI 모델의 활용 영역이 빠르게 확장되면서, 프로젝트 목적에 맞는 최적의 모델을 선택하는 것이 더욱 중요해졌습니다. 본 프로젝트는 GPT, Gemini, Claude 등 주요 LLM을 동일한 조건에서 비교·평가하여, 각 모델이 어떤 상황에서, 어떤 사용자에게 가장 유용한지까지 심층적으로 분석합니다.



왜 LLM 신뢰도 비교가 필요한가?

LLM은 강력한 도구이지만, 사실 오류와 Hallucination이 빈번하게 발생하여 그 신뢰성에 대한 정량적이고 체계적인 평가가 필수적입니다.

모델별 사실 오류(Hallucination) 발생

LLM은 훈련 데이터의 한계로 인해 사실과 다른 내용을 그럴듯하게 말하는 Hallucination 문제가 빈번히 발생합니다. 따라서 “어떤 모델이 가장 덜 틀리는가?”를 비교할 필요가 있습니다.

동일 질문에 대한 성능 편차

같은 질문이라도 모델마다 정확도와 답변 일관성이 크게 다릅니다. 특히 최신 정보, 수치 계산, 복잡한 reasoning에서 차이가 극명하게 드러나 업무·서비스 환경에 직접적인 영향이 발생합니다.

신뢰도 기반의 정량적 비교 필요

정확한 평가 없이 “느낌”으로 모델을 선택할 수는 없습니다. 정답률, 안정성(분산), 난이도별 성능, Skill Tag별 성능 등 정량적인 비교 기준을 세워 모델의 강점·약점을 명확히 파악해야 합니다.

실제 활용을 위한 모델 선택 기준 확보

LLM을 활용하는 목적(연구/서비스/업무 자동화 등)에 따라 어떤 모델이 가장 적합한지 판단할 수 있는 근거가 필요합니다. 모델별 특성을 파악하면 리스크 (Hallucination)를 줄이고, 보다 안정적으로 LLM을 적용할 수 있습니다.

우리가 달성하고자 하는 목표

본 프로젝트는 단순한 정확도 비교를 넘어, LLM의 구조적인 특성을 분석하여 심층적인 이해를 목표로 합니다.

사실 기반 정답률 비교

각 LLM이 사실 기반 질문에 얼마나 정확하게 답하는지 정량적으로 평가합니다.

Skill Tag별 모델 성능 분석

다양한 스킬(예: 사실, 수치, 추론)별로 모델의 강점과 약점을 파악합니다.

난이도별 정답률 비교

쉬움, 중간, 어려움 난이도에 따른 모델의 성능 변화를 분석합니다.

이미지 기반 질문 성능 테스트

멀티모달 LLM의 이미지 이해 및 처리 능력을 평가합니다.

Hallucination 유형별 오류 분석

Hallucination이 어떤 유형으로 발생하는지 질적으로 분석하고 비교합니다.

모델 안정성(Stability) 분석

동일한 질문에 대한 모델 응답의 일관성을 통해 안정성을 평가합니다.


PART

02

데이터셋 구축 & 실험 설계

LLM 성능 비교 실험을 위해 질문 데이터셋 구성,
응답 수집 방식, 정답 구축 방법, 전체 실험 파이프라인을 소개합니다.

종합적인 실험 파이프라인



▶ 본 프로젝트는 질문 데이터 생성부터 LLM 응답 수집, 정답 비교 기반의 자동 채점, 그리고 시각적 분석까지 이어지는 평가 파이프라인으로 구성되었습니다.

32개 문항 질문 데이터셋 구축 (questions.csv)

저희는 GPT, Claude, Gemini의 신뢰도를 비교하기 위해 직접 구축한 32개의 질문 데이터셋을 활용했습니다.

- 텍스트 기반 28문항

다양한 지식 영역을 아우르는 텍스트 기반 질문들로 구성되었습니다.

- 이미지 기반 4문항

멀티모달 LLM의 시각 정보 이해 능력을 평가하기 위한 문항이 포함되었습니다.

- 상세 분류

각 문항은 category_english, category_korean, skill_tag, difficulty(easy/medium/hard)로 세분화하여 분석의 깊이를 더했습니다.

fact (사실)	4
numerical (수치 기반)	4
definition (정의 설명)	4
recent (최신 정보)	4
reasoning (추론)	4
comparison (비교)	4
misconception (오해)	4
image (이미지 이해)	4

이미지 기반 질문 예시

멀티모달 평가의 중요성을 강조하기 위해 다양한 시각 자료를 활용한 질문들을 포함했습니다.



❏ 이러한 멀티모달 질문은 LLM이 단순히 텍스트를 처리하는 것을 넘어, 실제 시각 정보를 얼마나 잘 이해하고 추론하는지를 보여줍니다.

정답 구축 방식 (answers.csv)

정확한 모델 평가를 위해 모든 질문에 대한 신뢰성 높은 정답을 공식 출처 기반으로 직접 구축했습니다.

- 공식 출처 기반: Wikipedia, 정부 공식 문서, 학술 자료 등 신뢰할 수 있는 출처를 통해 정답을 검증하고 기록했습니다.
- 계산형 문제 직접 산출: 계산이 필요한 문제는 직접 풀이하여 정확한 값을 도출했습니다.
- 이미지 문항 분석: 이미지 기반 4문항은 이미지 내의 실제 비율이나 값을 직접 계산하여 정답으로 입력했습니다.

Q02	인류가 처음 달에 착륙한 해는 언제인가?	1969년	Wikipedia
Q07	2024년 대한민국 1인당 국민총소득 (GNI)은 약 얼마인가?	약 49,955,000원(약 5,000만원) 또는 36,624달러이다	한국은행
Q31	혁주와 은영, 준수가 각각 좋아하는 운동이 무엇인지 말하시오	혁주-농구, 은영-테니스, 준수-축구	이미지 분석

응답 구축 방식 (responses.csv)

공정한 비교와 재현성 확보를 위해 엄격한 실험 환경을 구축했으며, 앞으로의 확장 가능성도 고려했습니다.

응답 수집 조건

→ 동일 모델 비교

GPT, Claude, Gemini 세 가지 주요 LLM을 선정하여 무료 모델을 기준으로 비교했습니다. (무료 버전 사용)

→ 동일 프롬프트 사용

모든 모델에 동일한 질문 프롬프트를 사용하여 일관성을 유지했습니다.

→ 출력 규칙 기반 창의성 억제

모든 모델에 설명·추론·추가 정보를 금지하고 단일 문장 형식을 강제하는 엄격한 프롬프트 제약을 적용하여 출력의 변동성과 창의성을 최소화했습니다.

→ 데이터 저장 및 전처리

수집된 응답은 responses.csv에 저장하고, 불필요한 줄바꿈이나 기호 제거 등의 전처리를 수행했습니다.

출력 제약 기반 통제(Prompt Constraints)

프롬프트 제약조건

- 간단한 질문의 경우 답변을 한 문장으로 강제
- "X는 Y이다."의 형식으로 답변 통일
- 설명·추론·불필요한 정보 금지
- 이미지 문제는 이미지에 보이는 정보만 사용
- 형식 오류 발생 시 → 형식 제약 완화, 반드시 답변 생성

responses.csv 구축

ID	MODEL	RESPONSE
----	-------	----------

→ 데이터 수집 및 전처리


- 질문 × 모델 = 총 96개 응답 데이터 생성
- 모델 이름, 질문 ID, 최종 응답을 responses.csv로 정리
- 자동 채점을 위해 특수문자·줄바꿈 등 텍스트 정제 수행

PART

03

LLM 성능 비교를 위한 6가지 핵심 평가 기준

LLM의 진정한 역량을 파악하기 위해 다음 6가지 체계적인 기준을 기반으로 Fact vs Fiction 테스트를 수행했습니다.



난이도 분류

문항의 복잡성 수준



Skill Tag 8종

필요한 인지 능력



환각 유형 6종

오류 패턴 분석



채점 기준

정확성 평가 척도



채점함수 구조

채점 프로세스



특수 규칙

복잡 문항 처리

난이도 기준 정의

문제의 복잡성에 따라 Easy, Medium, Hard의 세 가지 난이도 기준으로 분류했습니다.
이는 LLM의 다양한 성능 패턴을 이해하는 데 중요한 기반이 됩니다.

1

Easy

단일 사실, 단일 정의, 단순 수치 기억형 문제. 예: "OO의 수도는?", "OO의 정의는?"

2

Medium

간단 계산, 비교, 두 단계 추론, 최신 정보 활용 문제. 예: 비율 계산, 두 수치 비교, 최근 이슈 기반 질문

3

Hard

다단계 계산, 복합 추론, 오해/함정 판단 문제. LLM이 자주 틀리는 유형(수치 추론 + 함정 문장 등) 중심

난이도별 정답률과 모델 성능 차이를 함께 분석해, 어떤 모델이 복잡한 상황에서 더 잘 대답하는지 확인합니다.

Skill Tag 정리

문제 유형을 세분화하기 위해 8가지 Skill Tag를 정의했습니다. 각 태그는 LLM이 평가될 지식과 추론 능력을 나타냅니다.



SIMPLE_FACT

단순 사실 확인: 날짜, 인물, 용어 등 기본적인 사실 질문



CONCEPT_DEFINITION

개념 정의: 개념, 용어, 원리 등을 설명하는 문제



NUMERIC_REASONING_MULTI

다단계 수치 추론: 여러 단계를 거쳐 계산·추론해야 하는 문제



MISCONCEPTION_JUDGEMENT

오해·오답 판단: 주장이 사실인지, 잘못된 정보인지 판별



NUMERIC_FACT

숫자 기반 사실: 정확한 수치·비율·값을 직접 알아야 하는 문제



RECENT_FACT

최신 정보 기반: 최근 사건, 통계 등 '시점'이 중요한 질문



COMPARATIVE_REASONING

비교·대조 추론: 둘 이상의 정보를 비교하여 판단



IMAGE_REASONING

이미지 기반 추론: 이미지, 그래프 등 시각적 정보 이해 및 추론

Hallucination 유형 분류 규칙

모델의 오류 패턴을 구조적으로 비교하기 위해 6가지 Hallucination 유형을 정의했습니다. 이는 단순 오류를 넘어선 질적 분석을 가능하게 합니다.

1

Fabrication

완전히 존재하지 않는 정보를 지어내는 경우.
사실 왜곡, 존재하지 않는 정보 창작

2

Unsupported Detail

부분적으로는 사실이나, 특정 세부 사항이 뒷받침되지 않는 경우.
근거 없는 추가 정보

3

Overconfidence

불확실한 정보를 확신에 찬 어조로 제시하는 경우.
틀렸는데 확신형으로 말함

4

Misunderstanding

질문의 의도를 잘못 이해하여 엉뚱한 답변을 하는 경우.

5

Logical Inconsistency

답변 내부에 논리적 모순이 존재하는 경우.
단위/비율/논리적 모순

6

None

Hallucination이 발견되지 않은 정확한 답변.
허위정보 없음

LLM 성능 평가 채점 방법론

LLM 응답의 미묘한 차이를 반영하기 위해 세분화된 채점 기준을 마련했습니다.
이는 단순히 정답/오답으로만 평가할 때 발생할 수 있는 편향을 줄여줍니다.

1. 채점 규칙 요약 (Scoring Rules Summary)

각 문제(항목)는 답변의 품질과 정확도에 따라 0점에서 1점 사이의 점수를 부여받으며, 주요 채점 기준은 다음과 같이 세분화된다.

점수 (Score)	등급 (Grade)	채점 규칙 (Scoring Rule)	설명
1	정답 (Correct)	답변이 사실 관계 및 요구 사항을 완벽하게 충족함	오류나 부정확한 내용이 전혀없는 완전한 답변
0.5	부분 정답/불완전 (Partial)	중요한 정보 누락·모호함 포함	요구 사항을 부분적으로만 충족하며 정확하지만 정밀도가 떨어짐
0	오답/환각 (Incorrect / Hallucination)	답변이 틀렸거나 사실과 다른 내용을 생성	치명적 오류(Factual Error) 포함 또는 질문과 무관한 답변

LLM 성능 평가 채점 방법론

2.문제 유형별 특수 채점 로직 (Scoring Logic by Question Type)

각 유형별로 점수를 0점으로 만드는 특수 감점 로직(Special Penalty Logic)이 다르게 적용됩니다.

문제 유형	주요 특징 및 평가 목표	특수 감점 로직(Special Penalty Logic)
Factual Error (사실적 사실 오류)	존재하지 않는 사실 생성(Hallucination), 핵심 사실 관계 오류 판단 → 신뢰성/안전성 리스크의 주 원인	특수로직 1: FactualError 사실 관계가 틀린 답변은 난이도·유형 무관 0점 처리
Comparative Reasoning (비교 추론)	여러 정보를 조합해 비교·대조하고 결론 도출 능력 평가	특수로직 2: 논리결함 비교 대상 간 핵심 논리 흐름 오류 또는 결론이 반대인 경우 0점
Numeric Reasoning Multi (다단계 수치 추론)	여러 단계의 계산·수치 정보를 조합하여 최종 답 도출	특수로직 3: 최종답오류 중요한 계산 오류 로 최종 답이 틀릴 경우 0.5점 처리

LLM 성능 평가 채점 방법론

문제 유형	주요 특징 및 평가 목표	특수 감점 로직 (Special Penalty Logic)
RECENT FACT (최신 정보)	모델 학습 이후의 최신 정보를 정확히 인지하고 답변하는 능력	특수로직4: 정보부재 최신 정보 자체를 인지하지 못하고 기존/과거 정보로 잘못 답하면 0점(최신성 결함)
Omission / Refusal (누락/거부)	답변을 생성하지 않거나 문제 해결 의지가 없다고 판단되는 경우	특수로직5: 답변거부 답변을 거부하거나 기술적 한계로 답변이 불가능한 경우 0점
Partial / Imprecise (부분적 오류)	요구된 내용을 충분히 포함하지 못하거나 설명이 모호·불완전한 경우	특수로직6: 불완전성 정확성은 있으나 요청된 요소 중 50% 이상 누락 시 0.5점
기타 (Concept Definition, Simple Fact 등)	정의, 단순 사실, 판단 등 명확한 정답이 존재하는 유형	표준 채점 적용 정답 1.0점 / 불완전 0.5점 / 오답 0점

LLM 성능 평가 채점 방법론

3. 최종 정확도 계산 수식 (Accuracy Calculation Formula)

각 모델의 최종 정확도 점수는 전체 평가 항목에 부여된 점수들의 **평균값**으로 산출됩니다.

1) 총 점수 합계 (S_total)

총 점수 합계는 각 문제에 부여된 점수(s_i)를 모두 더한 값입니다.

$$S_{total} = \sum_{i=1}^N s_i$$

- s_i : i번째 문제에 부여된 점수 (1.0, 0.5, 또는 0.0)
- N : 전체 평가 문제의 총 개수 (예: 64개)

2) 모델 종합 정확도 (Accuracy)


모델의 최종 정확도(Accuracy)는 총 점수 합계를 전체 문제 개수(N)로 나누어 계산합니다.

$$Accuracy = \frac{S_{total}}{N} = \frac{\sum_{i=1}^N s_i}{N}$$

채점 함수(evaluate_answer) 구조

정답 비교 기반의 구조화된 채점 프로세스

- 1단계:
입력 및 표준화 (Input & Standardization)
- 2단계:
특수 감점 로직 확인 (Special Penalty Logic Check)
- 0점 우선순위
- 3단계:
부분 정답 로직 확인 (Partial Scoring Check) - 0.5점
- 4단계:
최종 점수 확정 (Final Output)



모델별 성능 집계 수식

1) 모델별 평균 점수 (Accuracy)

모델 m 이 전체 문제에서 얻은 평균 정답률

$$\bar{s}_m = \frac{1}{N_m} \sum_{i \in m} s_i$$

- s_i = i 번째 문항의 채점값(정답=1, 오답=0)
 - N_m = 모델 m 이 답변한 전체 문항 수
- 각 모델의 전반적인 정답률 비교 지표

2) Hallucination 유형별 발생량

특정 오류 유형 h 가 모델에서 몇 번 발생했는지

$$C_{m,h} = \sum_{i \in m} \mathbf{1}(h_i = h)$$

- h_i = i 번째 문항의 오류 유형
- $\mathbf{1}(h_i = h)$ = 오류 유형이 h 이면 1, 아니면 0
- → fabrication / misunderstanding 등 오류 패턴 분석

3) 난이도별 평균 점수

난이도 d (예: 쉬움/보통/어려움)에서 모델이 얻은 평균 정답률

$$\bar{s}_{m,d} = \frac{1}{N_{m,d}} \sum_{i \in (m,d)} s_i$$

- $N_{m,d}$ = 모델 m 이 난이도 d 에서 답변한 문제 수
- 쉬움/보통/어려움 난이도별 강약 분석

4) Skill Tag별 평균 점수 (Heatmap 데이터)

스킬 태그 k 관련 문항에서의 모델 평균 점수

$$s_{m,k} = \frac{1}{N_{m,k}} \sum_{i \in (m,k)} s_i$$

→ 모델별로 어떤 영역에 강약이 있는지 한눈에 파악

PART

04


모델별 성능 분석

LLM 세 모델의 정확도, 안정성, Hallucination 경향, Skill Tag별 성능을 다각도로 비교·분석합니다.

채점된 결과는 result_table.csv로 저장되며, 이는 실험 파이프라인의 핵심 산출물입니다.

이후 analysis.ipynb에서 해당 데이터를 시각화하여 모델 성능을 직관적으로 분석하고 개선점을 도출합니다.

모델별 종합 정확도 (Overall Accuracy)



- 전체 평균 점수에서는 GPT가 0.8125로 1위를 기록하며 가장 안정적인 성능을 보임.
- Gemini(0.80)가 그 뒤를 바짝 쫓고 있으며, Claude(0.75)는 상대적으로 낮은 정확도를 기록함.

- GPT (0.81): 전반적인 질문 유형에서 가장 높은 정답률을 보이며, 일반적인 범용 작업에 가장 적합함.
- Gemini (0.80): GPT와 대등한 수준의 성능을 보이며, 특히 최신 정보 처리 능력 덕분에 높은 점수를 유지함.
- Claude (0.75): 비교 모델 중 가장 낮은 점수를 기록했으며, 특정 유형(비교 추론 등)에서의 약점이 전체 평균을 하락시킨 주원인으로 분석됨.

• Gemini > GPT > Claude


MODEL	AVERAGE SCORE
Claude	0.7500
GPT	0.8125
Gemini	0.7969

※ Accuracy는 모델의 전반적인 신뢰도를 평가하는 가장 기본 지표로, 이후 세부 분석(난이도·스킬별) 결과를 해석하는 기준점이 됩니다.

모델 전체 안정성 비교

분산(Variance)이란?

- 분산이 낮을수록 → 답변이 일관되고 안정적이라는 의미
- 분산이 높을수록 → 문항에 따라 성능 편차가 크고 예측하기 어려운 모델



모델별 안정성 결과

모델	분산(Variance)	안정성 평가
GPT	0.125	★ 가장 안정적
Gemini	0.1429	중간 수준
Claude	0.1613	성능 편차가 가장 큼

분산 분석 결과, GPT가 가장 안정적인 모델로 확인되었으며,
Claude는 문항 유형에 따라 성능 변동성이 가장 크게 나타나 안정성이 낮은 것으로 평가되었습니다.

난이도별 분산 분석 (Variance by Difficulty)

난이도별 분산 분석을 통해 모델별 숨겨진 특성을 파악할 수 있습니다.

Easy 난이도

- Easy 구간에서는 세 모델 모두 고르게 안정적임
- GPT와 Gemini가 가장 안정적이며, Claude는 약간 더 흔들리지만 차이는 크지 않음
- 즉, 기본적인 사실·단순 문제에서는 모델 간 안정성 차이가 거의 없음

Hard 난이도

- Claude와 Gemini는 0.0 → 매우 일관된 패턴
- (정답 또는 오답이 일정하게 반복)
- 반면 GPT는 0.5 → 세 모델 중 변동성이 가장 큼

난이도별 분산표

Difficulty	Claude	GPT	Gemini
Easy	0.111742	0.096591	0.096591
Medium	0.209967	0.121732	0.183007
Hard	0	0.5	0


Medium 난이도

- Medium 난이도에서 가장 큰 안정성 차이 발생
- GPT가 가장 안정적 (0.1217)
- Claude는 가장 높은 분산 → 문제 유형에 따라 결과가 크게 출렁임
- Gemini도 Easy보다 불안정성이 증가함

난이도별 핵심 결론

- Easy: 세 모델 모두 높은 안정성을 보이며 모델 간 차이가 거의 없음
- Medium: 안정성의 차이가 가장 크게 나타나는 구간, GPT가 가장 안정적
- Hard: GPT만 변동성이 크게 증가하며, Claude·Gemini는 오히려 일관성이 매우 높음


Hallucination 유형 분석 (Error Types)



MODEL	FACTUAL ERROR / HALLUCINATION (0점)	PARTIAL / IMPRECISE (0.5점)	TOTAL ERRORS
Claude	6	4	10
GPT	4	4	8
Gemini	5	3	8

- Claude는 총 오류 횟수(10회)가 가장 많을 뿐만 아니라, 치명적인 '사실 관계 오류(Factual Error)' 비율이 60%에 달해 신뢰성 리스크가 가장 높음.
- GPT와 Gemini는 총 오류 횟수가 8회로 동일하며 상대적으로 안정적임.
- Claude (위험): "없는 사실을 지어내는" 환각 현상(Factual Error)이 6건으로 가장 빈번함. 팩트 체크가 필수적인 작업에는 주의가 필요함.
- GPT (안정): 총 오류 8건 중 사실 오류와 부분 오류가 각각 4건씩 발생. 완전한 오답보다는 부정확한 답변의 비중이 상대적으로 있음.
- Gemini (양호): GPT와 유사한 오류 패턴을 보이나, 사실 오류가 5건으로 GPT보다 1건 더 많음.

난이도별 성능 비교 (Accuracy by Difficulty)



MODEL	EASY	MEDIUM	HARD
Claude	0.7917	0.6944	1.0000
GPT	0.8750	0.8056	0.5000
Gemini	0.8750	0.7222	1.0000

- "Easy/Medium" 난이도에서는 GPT가 강세를 보이지만, "Hard" 난이도에서는 성능이 0.50으로 급격히 하락하는 현상이 발생함.
- 반면, Claude와 Gemini는 "Hard" 난이도에서 1.0(만점)을 기록하며 복잡한 문제 해결에 더 강한 면모를 보임.
- GPT: 일반적인 난이도에서는 우수하나, 복잡한 추론이나 계산이 요구되는 고난이도(Hard) 문제에서 취약점 노출 (Score: 0.50).
- Claude/Gemini: 쉬운 문제에서 일부 실수가 있었으나, 어려운 문제(Hard)는 완벽하게 수행함. 이는 복잡한 로직 처리 능력이 GPT보다 우수할 가능성을 시사함.
- 인사이트: 단순 업무에는 GPT, 고도화된 추론이 필요한 업무에는 Gemini나 Claude가 더 적합할 수 있음.

세부 역량별 성능 (Skill Tag Heatmap)



- Gemini는 최신 정보(Recent Fact) 처리에서 유일하게 만점을 기록하며 독보적인 강점을 보임.
- Claude는 비교 추론(Comparative Reasoning) 역량이 0.25로 매우 낮아, 대상을 비교 분석하는 작업에 부적합함.
- Gemini (강점 - 최신성): RECENT_FACT 항목에서 1.0을 기록(타 모델은 0점대). 실시간 정보나 최신 트렌드 반영이 필요한 작업에 최적.
- Claude (약점 - 비교 분석): COMPARATIVE_REASONING 점수가 0.25로 치명적임. 여러 대상을 비교하거나 장단점을 분석하는 질문에 취약함.
- GPT (약점 - 복합 수치): NUMERIC_REASONING_MULTI에서 0.50을 기록. 단계가 복잡한 계산 문제에서 오류를 범할 확률이 높음.
- 공통: 모든 모델이 NUMERIC_FACT(단순 수치 확인)에서는 1.0을 기록하여, 단순 데이터 조회 능력은 상향 평준화됨.

MODEL / SKILL	COMPARATIVE_REASONING	CONCEPT_DEFINITION	MISCONCEPTION_JUDGEMENT	NUMERIC_FACT	NUMERIC_REASONING_MULTI	RECENT_FACT	SIMPLE_FACT	IMAGE_REASONING
Claude	0.250	0.900	0.500	1.000	1.000	1.000	0.750	0.625
GPT	0.625	0.900	0.625	1.000	0.500	1.000	0.750	1.000
Gemini	0.500	0.800	0.750	1.000	0.833	1.000	0.750	0.750

PART

05

종합 비교

모델별 분석 결과를 바탕으로 각 모델의 강점과 한계를 종합적으로 정리합니다.
난이도·유형별 성능 특징을 고려해 실제 활용 목적에 적합한 모델 선택 가이드를 제시합니다.

모델별 요약: 정확도와 안정성

각 모델의 강점과 약점을 파악하여 상황에 맞는 최적의 모델을 선택할 수 있습니다.

정확도: 1위 (0.8125)

GPT

• 안정성:

전체 분산 최저(0.125) → 가장 안정적인 모델
Easy·Medium 난이도에서 흔들림이 거의 없음

• 특징:

범용 작업에 가장 적합한 “균형형 모델”
다양한 질문 유형에서도 consistently 높은 성능
실전형·일반 사용자용 챗봇 모델로 최적화되어 있음

정확도: 2위 (0.80)

Gemini

• 안정성:

전체 안정성 중간 수준 (0.1429)
Easy 난이도에서 안정적이지만 Medium·Hard에서
변동성이 증가

• 특징:

최신 정보 처리 능력 가장 뛰어남 (Recent Fact 강점)
복잡한 추론·분석에서 GPT에 근접한 성능

정확도: 3위 (0.75)

Calude

• 안정성:

세 모델 중 가장 불안정 (Variance 0.1613)
Medium 난이도에서 변동 폭이 크게 증가

• 특징:

비교·추론형 문제에서 취약
다만 고난도 사고 영역에서 특정 패턴으로 강점이
나타날 때도 있음

종합 정리

- 정확도(Accuracy): GPT > Gemini > Claude
- 안정성(Variance): GPT > Gemini > Claude
- GPT는 정확도와 안정성 모두에서 가장 뛰어난 범용 모델이며,
- Gemini는 최신 정보와 복잡한 추론에서 강점을 보이는 균형형 모델,
- Claude는 성능 변동과 사실 오류가 상대적으로 커서 신뢰도가 중요한 작업에서는 주의가 필요한 모델이다.

최종 모델 성능 비교표

1) 모델별 핵심 성능 요약 표

아래의 비교 표는 각 모델이 실제 질문들에 대해 얼마나 정확하게 응답했는지를 정량적으로 보여주며, 모델 신뢰도를 평가하는 핵심 지표로 활용됩니다.

항목	Claude	GPT	Gemini
총 오류 횟수	10회 (최다)	8회	8회
사실 오류(Factual Error)	6회 (60%)	4회	5회
부분적 오류(Partial)	4회	4회	3회
종합 정확도(Accuracy)	0.75	0.8125 (1위)	0.7969
난이도별 - Easy	0.7917	0.875	0.875
난이도별 - Medium	0.5944	0.8065	0.7222
난이도별 - Hard	1	0.5000 (취약)	1
최신 정보(RECENT FACT)	0.75	1	1
비교 추론(COMPARATIVE)	0.25 (취약)	0.625	0.5
수치 추론 단순(NUMERIC FACT)	1	1	1
수치 추론 복합(NUMERIC MULTI)	1	0.50 (취약)	0.833
이미지 추론(IMAGE REASONING)	0.625	1	0.75

※ 성능 점수(Accuracy)는 0~1 사이의 값이며, 1에 가까울수록 더 좋은 성능을 의미합니다.

최종 모델 성능 비교표

2) 모델별 특징·강점·약점 종합 정리

모델	정확성(Accuracy)	오류 리스크	강점	약점
GPT	0.8125 - 1위	낮음	전반적 정확도 최고, Easy/Medium 강함, 최신 정보 처리 우수	Hard 난이도 복합 수치 추론 취약
Gemini	0.7969 - 2위	중간	최신 정보 처리 최강, Hard 난이도 최고	비교 추론 약함, 이미지 성능 보통
Claude	0.7500 - 3위	높음 (사실 오류 60%)	Hard 난이도 강함	팩트 오류 많음, 비교 추론 매우 약함

GPT는 전체적 정확성 1위, Gemini는 최신 정보·Hard 난이도 강점, Claude는 사실 오류 비율이 높아 위험도가 가장 크다.

PART

06

결론 & 시사점

모델별 성능 차이를 통해 LLM의 정확도·안정성·Hallucination 특성의 중요성을 확인했습니다.
이를 바탕으로 상황에 맞는 모델 선택 기준과 LLM 활용 시 주의해야 할 방향성을 제시합니다.

종합결론

GPT, Gemini, Claude 세 모델은 동일한 조건에서 비교한 결과, 정확도·안정성·Hallucination 발생 패턴에서 뚜렷한 차이를 보입니다.

GPT


- 전체 평균 정확도 0.8125(1위)
- 전체 분산 0.125(최저)
- 전반적 신뢰도와 안정성이 가장 뛰어난 범용 모델

Gemini

- 최신 정보 기반 문항(Recent Fact)에서 유일하게 1.0을 기록
- Hard 난이도 문항에서는 GPT보다 강한 성능
- 최신성·복잡 추론에서 경쟁력 확보

Claude

- Hard 난이도에서 높은 정답률을 기록했으나
- Factual Error 비율이 가장 높아 신뢰성 리스크가 큼
- 창의적 장문 생성에는 장점, 사실 기반 업무에는 주의 필요



시사점 1

어떤 상황에서 어떤 모델을 쓸 것인가?

LLM(Large Language Model) 도입을 고려할 때, 각 모델의 강점과 약점을 이해하는 것이 중요합니다.
특정 업무에 최적화된 모델을 선택하여 효율성과 정확성을 극대화할 수 있습니다.

정확성과 안정성이 중요한 업무

✓ 업무 예시

- 리포트 작성
- 기본 정보 제공
- 개념/정의 설명
- 일반적 질의응답

→ GPT 추천

→ 이유 : 높은 정확도 + 낮은 분산 +
다양한 Skill Tag에서 균형 잡힌 성능

최신 정보·복잡한 추론· 수치 기반 판단

✓ 업무 예시

- 기술 동향 요약
- 수치 계산·비교 중심 의사결정
- 데이터 분석·코드 리뷰

→ Gemini 추천

→ 이유 : Recent Fact 1.0,
Hard 난이도에서 강한 성능

창의적 글쓰기, 스토리텔링, 아이디어 발산

✓ 업무 예시

- 홍보 문구
- 장문 스토리텔링
- 기획 초기 아이디어 발산

→ Claude 추천

→ 이유 : 서술 구조화와 창의적 응답 Good
⚠ 단, Fact Error 비율이 높으므로 정보성
문서에는 부적합 → 검증 필수

GPT: 안정적이고 균형 잡힌 모델

추천대상

- 대학생·연구자 (리포트, 정보 검증, 요약)
- 기업 실무자 (정확성·일관성 요구)
- 교육/튜터링 목적 (기본 지식 기반 설명)

이유

- 모든 난이도에서 안정적인 성능 발휘
- 비교·논리 추론 및 최신 정보 처리 우수
- 실사용에서 리스크가 가장 낮은 모델

GPT는 실험에서 전체적으로 가장 높은 정확도와 낮은 변동성을 기록하며, 다양한 난이도·질문 유형에서 안정적인 성능을 제공하는 범용 모델로 확인되었습니다.

특히 정보 검증·요약·기본 개념 설명처럼 정확성과 신뢰성이 중요한 작업에서 위험도가 가장 낮은 모델로 평가되어, 이러한 요소가 중요한 사용자에게 가장 적합한 모델이라고 볼 수 있습니다.



Gemini: 최신 정보 및 고난도 문제 해결 ✨

추천대상

- 최신 동향·업데이트가 중요한 사용자
- 코드·데이터 관련 테크 직군
- 계산·추론이 필요한 분석 업무

이유

- Recent Fact 1.0, 최신 정보 처리 강점
- Hard 난이도 문항 전부 정답
- GPT와 유사한 정확도 + 더 높은 최신성

Gemini는 최신 정보 처리와 고난도 문제에서 우수한 성능을 보여, 변화가 빠른 환경에서도 신뢰도 있게 활용할 수 있는 모델로 평가되었습니다.
특히 최신성·추론·계산 정확성이 중요한 사용자에게 매우 적합하며, 기술·데이터 중심 업무에서 실질적 효용이 높은 선택지로 볼 수 있습니다.



Claude: 창의적 글쓰기·브레인스토밍 특화 모델

추천대상

- 스토리텔링·서사 중심 글 작성자
- 마케팅·기획 초안 작업
- 아이디어 브레인스토밍
- 장문 생성이 중요한 사용자

이유

- 자연스러운 문장 전개와 장문 생성 품질 우수
- 복잡한 아이디어를 구조화하는 능력이 뛰어남
- Hard 난이도 기반 추론 문제에서도 높은 성능

Claude는 창의적 글쓰기와 아이디어 발산에서 가장 강점을 보이며, 서사 구성과 장문 생성이 필요한 작업에서 높은 활용도를 가진 모델로 평가되었습니다.

다만 Fact Error 비율이 상대적으로 높아 사실 기반 문서 작성에는 부적합하며, 정확성이 중요한 작업에서는 GPT·Gemini가 더 적합한 선택지로 볼 수 있습니다.

시사점 2

LLM 평가 및 선택에 대한 인사이트

LLM을 신뢰성 있게 평가하고 목적에 맞는 모델을 선택하기 위해서는 단일 지표를 넘어선 다차원적 관점이 필요합니다.

1

다차원적 지표의 중요성

정확도만으로는 모델의 특성을 설명하기 어려우며, 난이도·Skill Tag·Hallucination 유형·안정성(분산)을 함께 분석해야 모델의 실제 역량과 취약점을 정확하게 파악할 수 있습니다.

2

재사용 가능한 평가 프레임워크

본 프로젝트에서 사용한 [스코어링 규칙\(0 / 0.5 / 1\)](#)과 [Skill Tag 기반 분석 프레임워크](#)는 향후 다른 LLM 비교 실험이나 서비스 도입 의사결정에도 [재사용 가능한 평가 템플릿](#)으로 활용될 수 있습니다. 이는 일관된 평가 기준을 제공합니다.

3

목적 기반 모델 선택 지원

모델의 강·약점을 다층적으로 파악함으로써
“가장 강한 모델”이 아니라 업무 목적에 최적화된 모델을 선택할 수 있게 합니다.

이러한 통합적 평가 방식은 모델 선택의 불확실성을 줄이고, 실제 비즈니스 환경에서 성공적인 LLM 도입을 가능하게 합니다.

한계 및 향후 과제

현재 연구의 한계를 명확히 인지하고 이를 기반으로 향후 연구 방향을 제시하는 것은 평가 체계의 신뢰성 향상을 위해 필수적입니다.

현재 연구의 한계

- 비교에 사용된 문항 수가 제한적이어서 통계적 일반화에 제약이 있습니다.
- 특정 도메인 중심의 질문 구성으로, 다양한 활용 맥락을 충분히 반영하지 못했습니다.
- 사용된 지표들이 LLM의 전체적 성능·행동 특성을 모두 포착하지 못할 가능성이 있습니다.

향후 확장 연구 방향

- 더 다양한 질문 유형과 상황을 포함한 대규모 평가 세트 확장이 필요합니다.
- 한국어뿐 아니라 다국어 기반 LLM 비교 연구를 통해 언어별 성능 차이를 검증해야 합니다.
- 최신 모델 출시 주기가 빠른 만큼, 정기적인 모델 업데이트·재평가 체계 구축이 요구됩니다.

❏ 이러한 확장 연구는 본 평가 프레임워크의 외연을 넓히고, 보다 신뢰도 높은 LLM 선택 기준을 마련하는 데 기여할 것입니다.
나아가 실제 비즈니스·학술 환경에서 모델 선택의 정확도를 높이고, LLM 활용 전략을 지속적으로 발전시킬 수 있는 기반을 제공할 것입니다.

Appendix

질문 (question.csv)_32개

정답 (answers.csv)_32개

응답(responses.csv)_96개

32개 질문 문항 (questions.csv)

id	category	category	question	skill_tag	difficulty
1	fact	사실 기억	세계에서 가장 오래된 대학은 어디인가?	SIMPLE_FACT	easy
2	fact	사실 기억	인류가 처음 달에 착륙한 해는 언제인가?	SIMPLE_FACT	easy
3	fact	사실 기억	노벨상을 최초로 수상한 여성은 누구인가?	SIMPLE_FACT	easy
4	fact	사실 기억	세계에서 가장 긴 강은 무엇인가?	SIMPLE_FACT	easy
5	numeric	수치 기반	대한민국의 2024년 출생아 수는 얼마인가?	NUMERIC_FACT	medium
6	numeric	수치 기반	지구의 적도 둘레 길이는 약 몇 km인가?	NUMERIC_FACT	medium
7	numeric	수치 기반	2024년 대한민국 1인당 국민총소득(GNI)은 약 얼마인가?	NUMERIC_FACT	medium
8	numeric	수치 기반	대한민국의 2025년 최저임금은 시간당 얼마인가?	NUMERIC_FACT	easy
9	definitio	정의 설명	기계학습에서 ‘과적합(overfitting)’이란 무엇인가?	CONCEPT_DEFI	easy
10	definitio	정의 설명	물리학에서 ‘엔트로피(entropy)’란 무엇인가?	CONCEPT_DEFI	medium
11	definitio	정의 설명	경제학의 ‘인플레이션(inflation)’을 정의하라.	CONCEPT_DEFI	easy
12	definitio	정의 설명	인공지능에서 ‘강화학습(reinforcement learning)’이란 무엇인가?	CONCEPT_DEFI	medium
13	recent	최신 정보	2024년 미국 대선에서 주요 후보는 누구였는가?	RECENT_FACT	medium
14	recent	최신 정보	2025년 노벨 물리학상 수상자는 누구였는가?	RECENT_FACT	medium
15	recent	최신 정보	2024 파리 올림픽 개막일은 언제였는가?	RECENT_FACT	easy
16	recent	최신 정보	2025년 공개된 영화 케이팝 데몬 헌터스의 감독은 누구인가?	RECENT_FACT	medium

32개 질문 문항 (questions.csv)

id	category_english	category_korean	question	skill_tag	difficulty
17	reasoning	다단계 추론	최저임금 10,030원으로 하루 6시간·주 5일 근무할 때 한 달(4주 기준) 월급과 3.3% 공제 후 실수령액을 계산하라. (※주휴수당 미포함. 공제액 계산 시 반올림하여 구하시오)	NUMERIC_REASONING_MULTIT	hard
18	reasoning	다단계 추론	A앱(기본 3,000원 + 1km당 700원)과 B앱(기본 5,000원 고정) 중 가게가 3km 떨어져 있을 때 더 저렴한 앱은 어느 쪽인가?	NUMERIC_REASONING_MULTIT	medium
19	reasoning	다단계 추론	카페 A(5잔 구매 시 1잔 무료)와 카페 B(10잔 구매 시 3잔 무료) 중 총 15잔을 구매할 때 더 이득인 쪽은 어느 카페인가?	COMPARATIVE_REASONING	medium
20	reasoning	다단계 추론	한 달에 5편 영화를 볼 경우 연간 시청 편수는 몇 편이며, 넷플릭스 월 17,000원 기준 1편당 비용은 얼마인가?	NUMERIC_REASONING_MULTIT	medium
21	comparison	비교	MacBook(air M2)과 Windows 노트북(Galaxy Book4)의 성능·호환성·사용성 차이를 비교하라.	COMPARATIVE_REASONING	easy
22	comparison	비교	대방역→한양대 이동 시,버스 이용과 지하철 이용 중 어떤 방식이 더 효율적인가?버스번호와 지하철 번호를 포함한 실제 추천 노선을 설명해라	COMPARATIVE_REASONING	medium
23	comparison	비교	풍력발전과 태양광발전의 장단점을 비교하라.	COMPARATIVE_REASONING	medium
24	comparison	비교	정규화(normalization)와 표준화(standardization)의 차이를 설명하라.	CONCEPT_DEFINITION	easy
25	misconception	흔한 오해	인간이 뇌의 10%만 사용한다는 주장은 사실인가?	MISCONCEPTION_JUDGMENT	medium
26	misconception	흔한 오해	소가 빨간색을 보면 흥분한다는 말은 사실인가?	MISCONCEPTION_JUDGMENT	medium
27	misconception	흔한 오해	비타민 C가 감기를 예방한다는 말에 과학적 근거가 있는가?	MISCONCEPTION_JUDGMENT	medium
28	misconception	흔한 오해	설탕이 아이들을 과잉행동((Hyperactivity and sugar))하게 만든다라는 주장은 사실인가?	MISCONCEPTION_JUDGMENT	medium
29	image	이미지 이해	다음은 문구점별 팔린 공책의 수를 나타낸 그림그래프입니다. 무지개 문구점과 개념 문구점에서 팔린 공책은 모두 몇 권인지 계산하고, 풀이 과정을 서술하시오	image_reasoning	medium
30	image	이미지 이해	다음 막대그래프를 보고, 학생들이 가장 좋아하는 과일이 무엇이며, 해당 과일을 좋아하는 학생 수는 몇 명인지 답하시오.	image_reasoning	easy
31	image	이미지 이해	혁주와 은영, 준수가 각각 좋아하는 운동이 무엇인지 말하시오	image_reasoning	easy
32	image	이미지 이해	다음 원그래프는 한 달 동안 소비한 곡물의 비율을 나타낸 것입니다. 전체 곡물 소비량이 800kg일 때, 쌀·보리·콩·기타 각각의 소비량(kg)을 소비했나요?	image_reasoning	hard

정답 (answers.csv)

id	answer	source	source_url
1	모로코 페스의 알카라윈 대학교(Mosque and University Kairaouine).	Wikipedia - 알카라윈 대학교	https://ko.
2	인류가 처음 달에 착륙한 해는 1969년이다.	Wikipedia - Apollo 11	https://en.
3	노벨상을 최초로 수상한 여성은 마리 퀴리(Marie Curie)이다.	Wikipedia - Marie Curie	https://en.
4	세계에서 가장 긴 강은 일반적으로 나일강(Nile River)으로 알려져 있다.	Wikipedia - Nile	https://en.
5	대한민국의 2024년 출생아 수는 약 238,300명이다.	국가데이터처-2024년 출생 통계	https://ww
6	지구 적도 둘레 길이는 40075.017 km이다.	Wikipedia - Earth	https://en.
7	약 49,955,000원(약 5,000만원) 또는 36,624달러이다	한국은행-보도자료	https://ww
8	대한민국 2025년 최저임금은 시간당 10,030원이다.	최저임금위원회	https://ww
9	과적합은 모델이 훈련 데이터의 패턴뿐 아니라 노이즈까지 과도하게 학습해 새로운 데이터 성능이	Wikipedia - Overfitting	https://en.
10	엔트로피는 계의 무질서도 또는 가능한 미시상태 수와 관련된 물리량이며 자연 과정에서 증가한다.	Wikipedia - Entropy	https://en.
11	인플레이션은 재화·서비스의 전반적 가격 수준이 지속적으로 상승하는 현상이다.	Wikipedia - Inflation	https://en.
12	강화학습은 환경과 상호작용하며 보상을 최대화하는 행동을 학습하는 방법이다.	Wikipedia - Reinforcement Learning	https://en.
13	2024년 미국 대선 주요 후보는 카멀라 해리스(Kamala Harris)와 도널드 트럼프(Donald	Wikipedia - 2024 US Election	https://en.
14	2025년 노벨 물리학상은 존 클라크(John Clarke), 미셸 H. 드보레(Michel H.Devoret) , 존 마르	NobelPrize.org - Physics 2025	https://ww
15	2024 파리 올림픽 개막일은 2024년 7월 26일이다.	Wikipedia - 2024 Olympics	https://en.
16	‘KPop Demon Hunters’의 감독은 매기 강(Maggie Kang)과 크리스 아펠한스(Chris	Wikipedia - KPop Demon Hunters	https://en.
17	월급은 1,203,600원이며 3.3% 공제 후 실수령액은 약 1,163,881원이다.	직접 계산	
18	A앱 5,100원, B앱 5,000원으로 B앱이 더 저렴하다.	직접 계산	
19	총 15잔 기준 카페 B가 더 많은 무료 혜택을 제공하므로 더 이득이다. (A: 13잔 구매 필요, B: 12잔	직접 계산	
20	1년 기준 60편 시청, 1편당 비용은 약 3,400원이다.	직접 계산	

정답 (answers.csv)

id	answer	source	source_url
21	항목,MacBook Air M2,Galaxy Book4 Ultra 성능,Apple M2 칩으로 일반 작업·편집에 빠르고 안정적,Intel 고성능 CPU+NVIDIA RTX로 게임·AI·3D 작업에 유리 호환성,macOS 기반으로 대부분 앱 사용 가능하나 윈도우 전용 프로그램 일부 제 약 Windows 11 기반으로 하고,저보.저고 SW 드 실행해서 가자 너으		https://www.samsung.com/us/computing/galaxy-books/galaxy-book4-ultra/?utm_source=chatgpt.com , https://support.apple.com/en-us/111867?utm_source=chatgpt.com
22	대방역→한양대 이동,버스 이용: 대방역 인근 정류장에서 641번을 타고 문래역에서 2호선 환승->한양대역 하차 (환승 필요, 1시간 6분 소요),지하철 이용: 1호선 대방	네이버지도_길찾기	https://map.naver.com/p/directions/14129384.8544953,4510912.0795128,%EB%8C%80%EB%B0%A9%EC%97%AD
23	발전방식,장점,단점 태양광발전,"청정·무제한 에너지원; 필요장소에 설치 가능; 유지보수 용이·무인화 가능; 수명 길다","일사량 의존; 에너지밀도 낮음·설치면적 커짐; 설치장소 한정·시스 템 비용 높음; 초기투자비·발전단가 높음" 프레바저 "여러비 것이 어으.천저에너지 비라 이으 때 바.나 가리지 안고 바저 가	경기환경에너지진흥원	https://www.ggenery.or.kr/energy/content/story/story02_01_02?utm_source=chatgpt.com
24	정규화는 데이터를 일정 범위로 스케일링, 표준화는 평균 0·표준편차 1로 변환한다.	scikit-learn Preprocessing	https://scikit-learn.org/stable/modules/preprocessing.html
25	‘인간이 뇌의 10%만 사용한다’는 주장은 과학적 근거가 없는 신화이며, 뇌영상 연구에 따르면 인간은 대부분의 뇌 영역을 사용한다.	Scientific American - Do People Only Use 10 Percent of Their Brains?	https://www.scientificamerican.com/article/do-we-really-use-only-10/
26	소는 빨간색을 구분하지 못하며 움직임에 반응한다. 빨간색 때문에 흥분하는 것이 아니다.	LiveScience	https://www.livescience.com/33700-bulls-charge-red.html
27	비타민 C는 일반인의 감기를 예방하는 효과는 거의 없으나, 감기 증상 기간을 약간 줄일 수 있다는 연구 결과가 있다.	Cochrane Collaboration 웹사이트	https://www.cochrane.org/ko/evidence/CD000980_vitamin-c-preventing-and-treating-common-cold
28	현재까지의 연구 결과, 설탕 섭취와 아이들의 과잉행동(hyperactivity) 사이에는 명확한 과학적 인과관계가 없다.	미국 국립보건원 NIH 산하	https://medlineplus.gov/ency/article/002426.htm
29	53권, 무지개 문구점은 30권, 개념 문구점은 23권입니다. 따라서 무지개 문구점과 개념 문구점에서 팔린 공책은 모두 53권입니다.	직접 계산	
30	굴,14명	직접 계산	
31	혁주-농구,은영-테니스,준수-축구	직접 계산	
32	쌀-280(kg), 보리-224(kg),콩-176(kg),기타-120(kg)	직접 계산	

응답(responses.csv)_96개



id	model	responses	skill_tag	difficulty
1	GPT	세계에서 가장 오래된 대학은 알 카라위인 대학교이다.	SIMPLE_FACT	easy
2	GPT	인류가 처음 달에 착륙한 해는 1969년이다.	SIMPLE_FACT	easy
3	GPT	노벨상을 최초로 수상한 여성은 마리 퀴리이다.	SIMPLE_FACT	easy
4	GPT	세계에서 가장 긴 강은 나일강이다.	SIMPLE_FACT	easy
5	GPT	대한민국의 2024년 출생아 수는 약 23만 8천 3백 명이다.	NUMERIC_FACT	medium
6	GPT	지구의 적도 둘레 길이는 약 4만 7천 5백 km이다.	NUMERIC_FACT	medium
7	GPT	2024년 대한민국의 1인당 국민총소득(GNI)은 약 36,624 달러이다.	NUMERIC_FACT	medium
8	GPT	대한민국의 2025년 최저임금은 시간당 10,030원이다.	NUMERIC_FACT	easy
9	GPT	과적합은 모델이 학습 데이터에 지나치게 맞춰져 일반화 성능이 떨어지는 현상이다.	CONCEPT_DEFI	easy
10	GPT	엔트로피는 시스템의 무질서도나 불확실성의 정도를 나타내는 물리량이다.	CONCEPT_DEFI	medium
11	GPT	인플레이션은 상품과 서비스의 전반적인 가격 수준이 지속적으로 상승하는 현상이다.	CONCEPT_DEFI	easy
12	GPT	강화학습은 에이전트가 환경과 상호작용하며 보상을 최대화하도록 학습하는 기계학습 방법이다.	CONCEPT_DEFI	medium
13	GPT	2024년 미국 대선에서 주요 후보는 조 바이든과 도널드 트럼프이다.	RECENT_FACT	medium
14	GPT	2025년 노벨 물리학상 수상자는 존 클라크(John Clarke), 미셸 H. 데보레(Michel H. Devoret), 존 M. 마티니스(John M. Martinis)	RECENT_FACT	medium
15	GPT	2024 파리 올림픽 개막일은 7월 26일이다.	RECENT_FACT	easy
16	GPT	케이팝 데몬 헌터스 영화의 감독은 매기 강과 크리스 아펠한스이다.	RECENT_FACT	medium
17	GPT	월급은 $10,030 \times 6 \times 5 \times 4 = 1,20,360$ 원이다. 공제액 $3.3\% = 1,20,360 \times 0.033 \approx 3,972$ 원 실수령액 $= 1,20,360 - 3,972 \approx$	NUMERIC_REAS	hard
18	GPT	가게가 3km 떨어져 있을 때 더 저렴한 앱은 A앱이다.	NUMERIC_REAS	medium
19	GPT	총 15잔을 구매할 때 더 이득인 쪽은 카페 B이다.	COMPARATIVE_	medium
20	GPT	연간 시청 편수는 $5 \times 12 = 60$ 편이며, 1편당 비용은 $17,000 \times 12 \div 60 \approx 3,400$ 원이다.	NUMERIC_REAS	medium

응답(responses.csv)_96개



id	model	responses	skill_tag	difficulty
21	GPT	MacBook Air M2(MacBook Air M2)와 삼성 Galaxy Book4(Galaxy Book4 Pro 14)를 성능, 호환성, 사용성 관점에서 비교하면 다음과 같다: 1. 성능 MacBook Air M2는 Apple 실리콘 M2 칩을 탑재하여 싱글 코어 성능이 매우 우수하며, Geekbench 기준으로 Windows 기반 일부 노트북 대비 단일 스레드 작업에서 강점을 보인다. 반면 Galaxy Book4 시리즈(예: Ultra 모델)는 Intel Core Ultra 프로세서 및 고성능 GPU(NVIDIA RTX 40 시리즈)를 선택할 수 있어, 병렬 연산이나 그래픽 집약적인 작업(영상 편집, 렌더링 등)에서 더 높은 성능을 낼 수 있다. Samsung sec +1 그래픽 성능 측면에서도 MacBook Air M2의 GPU 점수가 Windows 노트북에서 일부 보고된 것보다 더 높다는 벤치마크 결과가 존재한다. Geekbench 다만 고성능 모델을 비교할 때는 Galaxy Book4 Pro나	COMPARATIVE_REASONING	easy
22	GPT	대방역 → 한양대 이동에서는 지하철이 더 효율적인 경우가 많다. 지하철 루트: 대방역(1호선)에서 1호선을 타고 시청역 등에서 2호선(순환선)으로 환승 → 한양대역(2호선) 하차. 버스 노선: 한양대 정문 앞 정류장으로 가는 버스는 121번, 302번, N62번, 2012번, 2014번, 2016번, 2222번 등이 있음. 비교	COMPARATIVE_REASONING	medium
23	GPT	풍력발전은 바람이 일정하게 불 때 효율이 높고 설치 면적당 발전량이 크지만, 바람이 약하거나 일정하지 않으면 발전량이 불안정하며 소음과 조망 문제, 조류 피해 등이 단점이다. 태양광발전은 햇빛만 있으면 안정적으로 발전할 수 있고 설치와 유지가 비교적 간편하지만, 일조량에 따라 발전량이 크게 달라	COMPARATIVE_REASONING	medium
24	GPT	정규화는 데이터를 0과 1 사이의 특정 범위로 변환하는 것이고, 표준화는 데이터를 평균이 0이고 분산이 1인 값으로 변환하는 것이다.	CONCEPT_DEFINITION	easy
25	GPT	인간이 뇌의 10%만 사용한다는 주장은 사실이 아니다.	MISCONCEPTION_JUDGEMENT	medium
26	GPT	소가 빨간색을 보면 흥분한다는 말은 사실이 아니다.	MISCONCEPTION_JUDGEMENT	medium
27	GPT	비타민 C가 감기를 예방한다는 말은 과학적 근거가 충분하지 않다.	MISCONCEPTION_JUDGEMENT	medium
28	GPT	설탕이 아이들을 과잉행동하게 만든다는 주장은 사실이 아니다.	MISCONCEPTION_JUDGEMENT	medium
29	GPT	무지개 문구점과 개념 문구점에서 팔린 공책은 53권이다.	image_reasoning	medium
30	GPT	가장 좋아하는 과일과 그 학생 수는 귤과 14명이다.	image_reasoning	easy
31	GPT	혁주는 농구와 축구이고 은영은 배드민턴이고 준수는 테니스이다.	image_reasoning	easy
32	GPT	쌀은 280kg고 보리는 224kg고 콩은 176kg고 기타는 120kg이다.	image_reasoning	hard

id	model	responses	skill_tag	difficulty
1	Claude	세계에서 가장 오래된 대학은 볼로냐 대학교이다.	SIMPLE_FACT	easy
2	Claude	인류가 처음 달에 착륙한 해는 1969년이다.	SIMPLE_FACT	easy
3	Claude	노벨상을 최초로 수상한 여성은 마리 퀴리이다.	SIMPLE_FACT	easy
4	Claude	세계에서 가장 긴 강은 나일강이다.	SIMPLE_FACT	easy
5	Claude	대한민국의 2024년 출생아 수는 23만 8300명이다.	NUMERIC_FACT	medium
6	Claude	지구의 적도 둘레 길이는 약 40075km이다.	NUMERIC_FACT	medium
7	Claude	2024년 대한민국 1인당 국민총소득은 약 36624달러이다.	NUMERIC_FACT	medium
8	Claude	대한민국의 2025년 최저임금은 시간당 10030원이다.	NUMERIC_FACT	easy
9	Claude	기계학습에서 과적합은 모델이 훈련 데이터에 지나치게 맞춰져 새로운 데이터에 대한 일반화 성능이 떨어지는 현상이다.	CONCEPT_DEFI	easy
10	Claude	물리학에서 엔트로피란 시스템의 무질서도나 불확실성을 나타내는 열역학적 상태함수이다.	CONCEPT_DEFI	medium
11	Claude	인플레이션은 일정 기간 동안 물가 수준이 지속적으로 상승하여 화폐의 구매력이 하락하는 현상이다.	CONCEPT_DEFI	easy
12	Claude	강화학습은 에이전트가 환경과 상호작용하며 보상을 최대화하는 행동을 학습하는 기계학습 방법이다.	CONCEPT_DEFI	medium
13	Claude	2024년 미국 대선에서 주요 후보는 도널드 트럼프와 카멀라 해리스이다.	RECENT_FACT	medium
14	Claude	2025년 노벨 물리학상 수상자는 존 클라크, 미셸 드보레, 존 마르티니스이다.	RECENT_FACT	medium
15	Claude	2024 파리 올림픽 개막일은 2024년 7월 26일이다.	RECENT_FACT	easy
16	Claude	2025년 공개된 영화 케이팝 데몬 헌터스의 감독은 매기 강과 크리스 아펠한스이다.	RECENT_FACT	medium
17	Claude	한 달 월급은 1,203,600원이고 3.3% 공제 후 실수령액은 1,163,881원이다.	NUMERIC_REAS	hard
18	Claude	더 저렴한 앱은 B앱이다.	NUMERIC_REAS	medium
19	Claude	총 15잔을 구매할 때 더 이득인 쪽은 카페 A이다.	COMPARATIVE_	medium
20	Claude	연간 시청 편수는 60편이며 1편당 비용은 3,400원이다.	NUMERIC_REAS	medium

id	model	responses	skill_tag	difficulty
21	Claude	MacBook Air M2는 성능과 배터리 효율이 우수하나 Windows 소프트웨어 호환성이 제한적이고, Galaxy Book4는 Windows 소프트웨어 호환성이 높으나 배터리 효율이 상대적으로 낮다.	COMPARATIVE_REASONING	easy
22	Claude	실시간 교통정보 없이는 최적 경로 판단이 불가능하다.	COMPARATIVE_REASONING	medium
23	Claude	풍력발전은 야간 발전이 가능하나 소음이 있고, 태양광발전은 무소음이나 일조량에 의존한다.	COMPARATIVE_REASONING	medium
24	Claude	정규화는 데이터를 0-1 범위로 변환하고, 표준화는 평균 0 표준편차 1로 변환한다.	CONCEPT_DEFINITION	easy
25	Claude	이 주장은 거짓이다.	MISCONCEPTION_JUDGEMENT	medium
26	Claude	이 주장은 거짓이다.	MISCONCEPTION_JUDGEMENT	medium
27	Claude	예방 효과는 미미하나 증상 기간을 약간 단축할 수 있다.	MISCONCEPTION_JUDGEMENT	medium
28	Claude	이 주장은 과학적으로 입증되지 않았다.	MISCONCEPTION_JUDGEMENT	medium
29	Claude	정답은 50권이다.	image_reasoning	medium
30	Claude	가장 좋아하는 과일은 귤이며 해당 학생 수는 14명이다.	image_reasoning	easy
31	Claude	혁주가 좋아하는 운동은 야구이고 은영이 좋아하는 운동은 테니스이고 준수가 좋아하는 운동은 축구이다.	image_reasoning	easy
32	Claude	쌀은 280kg, 보리는 224kg, 콩은 176kg, 기타는 120kg이다.	image_reasoning	hard

응답(responses.csv)_96개



id	model	responses	skill_tag	difficulty
1	Gemini	세계에서 가장 오래된 대학은 볼로냐 대학교이다.	SIMPLE_FACT	easy
2	Gemini	인류가 처음 달에 착륙한 해는 1969년이다.	SIMPLE_FACT	easy
3	Gemini	노벨상을 최초로 수상한 여성은 마리 퀴리이다.	SIMPLE_FACT	easy
4	Gemini	세계에서 가장 긴 강은 나일강이다.	SIMPLE_FACT	easy
5	Gemini	대한민국의 2024년 출생아 수는 23만 8천 3백 명이다.	NUMERIC_FACT	medium
6	Gemini	지구의 적도 둘레 길이는 약 40,075 km이다.	NUMERIC_FACT	medium
7	Gemini	2024년 대한민국 1인당 국민총소득(GNI)은 36,624달러 또는 5,012만 원이다.	NUMERIC_FACT	medium
8	Gemini	대한민국의 2025년 최저임금은 시간당 10,030원이다.	NUMERIC_FACT	easy
9	Gemini	기계학습에서 과적합은 훈련 데이터에 과도하게 적합하여 새로운 데이터에 대한 성능이 저하되는 현상이다.	CONCEPT_DEFI	easy
10	Gemini	물리학에서 엔트로피는 무질서도 또는 정보의 불확실성을 나타내는 물리량이다.	CONCEPT_DEFI	medium
11	Gemini	경제학에서 인플레이션은 한 나라의 시장 전체에서 상품과 서비스의 가격이 지속적으로 오르는 현상이다.	CONCEPT_DEFI	easy
12	Gemini	인공지능에서 강화학습은 어떤 환경 속에서 에이전트가 행동을 취하고 그 결과로 보상이나 벌칙을 받아 행동의 최적 전략을 스스로 학	CONCEPT_DEFI	medium
13	Gemini	2024년 미국 대선에서 주요 후보는 **도널드 트럼프와 카멀라 해리스**이다.	RECENT_FACT	medium
14	Gemini	2025년 노벨 물리학상 수상자는 존 클라크, 미셸 H. 드보레, 존 M. 마티니스이다.	RECENT_FACT	medium
15	Gemini	2024 파리 올림픽 개막일은 2024년 7월 26일이다.	RECENT_FACT	easy
16	Gemini	2025년 공개된 영화 케이팝 데몬 헌터스의 감독은 매기 강과 크리스 아펠한스이다.	RECENT_FACT	medium
17	Gemini	최저임금 10,030원으로 하루 6시간 주 5일 근무할 때 한 달(4주 기준) 월급과 3.3% 공제 후 실수령액은 세전 월급은 1,203,600원이	NUMERIC_REAS	hard
18	Gemini	가게가 3km 떨어져 있을 때 더 저렴한 앱은 A앱이다.	NUMERIC_REAS	medium
19	Gemini	총 15잔을 구매할 때 더 이득인 쪽은 카페 B이다.	COMPARATIVE_	medium
20	Gemini	한 달에 5편 영화를 볼 경우 연간 시청 편수는 60편이며 넷플릭스 월 17,000원 기준 1편당 비용은 3,400원이다.	NUMERIC_REAS	medium

id	model	responses	skill_tag	difficulty
21	Gemini	MacBook과 Windows 노트북의 성능·호환성·사용성 차이는 MacBook Air M2는 높은 최적화된 성능과 폐쇄적인 호환성을, Galaxy Book4는 다양한 소프트웨어 호환성과 폭넓은 사용성을 제공하는 것이다.	COMPARATIVE_REASONING	easy
22	Gemini	대방역에서 한양대 이동 시 더 효율적인 방식은 지하철 이용이며, 주요 추천 노선은 1호선 대방역에서 승차하여 2호선 한양대역으로 환승하는 노선이다.	COMPARATIVE_REASONING	medium
23	Gemini	풍력발전과 태양광발전의 장단점 비교는 풍력발전은 높은 발전 효율과 낮은 토지 활용도의 장점과 소음 및 환경 영향의 단점을, 태양광발전은 소음이 없고 쉬운 설치의 장점과 낮은 발전 효율 및 넓은 설치 면적의 단점을 가지는 것이다.	COMPARATIVE_REASONING	medium
24	Gemini	정규화와 표준화의 차이는 정규화는 데이터의 범위를 0과 1 사이로 조정하여 최소-최대 스케일링을 수행하는 것이고, 표준화는 데이터의 평균을 0, 표준편차를 1로 조정하여 Z-점수 스케일링을 수행하는 것이다.	CONCEPT_DEFINITION	easy
25	Gemini	인간이 뇌의 10%만 사용한다는 주장은 **과학적 근거가 부족한 근거 없는 통념**이다.	MISCONCEPTION_JUDGEMENT	medium
26	Gemini	소가 빨간색을 보면 흥분한다는 말은 시력적인 문제가 있어 사실이 아니다이다.	MISCONCEPTION_JUDGEMENT	medium
27	Gemini	비타민 C가 감기를 예방한다는 말에는 일반적인 사람을 대상으로 한 예방 효과에 대한 과학적 근거는 미흡하거나 없다이다.	MISCONCEPTION_JUDGEMENT	medium
28	Gemini	설탕이 아이들을 과잉행동하게 만든다는 주장은 대부분의 연구에서 과학적 증거가 발견되지 않은 통념이다.	MISCONCEPTION_JUDGEMENT	medium
29	Gemini	무지개 문구점과 개념 문구점에서 팔린 공책은 모두 65권이다.	image_reasoning	medium
30	Gemini	학생들이 가장 좋아하는 과일은 귤이며, 해당 과일을 좋아하는 학생 수는 14명이다.	image_reasoning	easy
31	Gemini	혁주와 은영, 준수가 각각 좋아하는 운동은 농구, 테니스, 축구이다.	image_reasoning	easy
32	Gemini	쌀은 280kg, 보리는 224kg, 콩은 176kg, 기타는 120kg을 소비했다.	image_reasoning	hard